



## **Workload metrics**

tokens/s · context · response-time



## **Serving metrics**

TTFT · TPOT · goodput · KV



## **Resource metrics**

GPU util · memory · bandwidth