

Read the book two ways: layer-by-layer (parts) or question-by-question (traceability)
each chapter supplies a derived quantity, which feeds a decision

Part I — The Token

517 tok → dec 516: critical reflective

↓ per-token picture 600: feedback

517 six-dim fingerprint

↓ what to characterize

Part II — The Workload

517 cap 516: 5% Greenoodput

↓ which model family measure & gate

Part III — The System

517 KV/ → 516: no 515: take core

↓ fit / compute vs memory-bound

517 par 516: 1 sat

↓ GPUs ↓ waiving slack

Part IV — The Architecture

517 can 516: tie 515: two-stage bmark

↓ synthesis 516: 500: reject

517 con 516: 500: 8 MFlops

↓ fleet saturation cloud/API

Part V — The Fleet

517 H 516: 500: KV approx

↓ fleet size multi-indep routing capacity

517 fle 516: 500: gate + rollback

↓ QPS vs host rollout

Part VI — The Architect

517 bot 516: 500: 515: 514: 513: 512: 511: 510: 509: 508: 507: 506: 505: 504: 503: 502: 501: 500: 499: 498: 497: 496: 495: 494: 493: 492: 491: 490: 489: 488: 487: 486: 485: 484: 483: 482: 481: 480: 479: 478: 477: 476: 475: 474: 473: 472: 471: 470: 469: 468: 467: 466: 465: 464: 463: 462: 461: 460: 459: 458: 457: 456: 455: 454: 453: 452: 451: 450: 449: 448: 447: 446: 445: 444: 443: 442: 441: 440: 439: 438: 437: 436: 435: 434: 433: 432: 431: 430: 429: 428: 427: 426: 425: 424: 423: 422: 421: 420: 419: 418: 417: 416: 415: 414: 413: 412: 411: 410: 409: 408: 407: 406: 405: 404: 403: 402: 401: 400: 399: 398: 397: 396: 395: 394: 393: 392: 391: 390: 389: 388: 387: 386: 385: 384: 383: 382: 381: 380: 379: 378: 377: 376: 375: 374: 373: 372: 371: 370: 369: 368: 367: 366: 365: 364: 363: 362: 361: 360: 359: 358: 357: 356: 355: 354: 353: 352: 351: 350: 349: 348: 347: 346: 345: 344: 343: 342: 341: 340: 339: 338: 337: 336: 335: 334: 333: 332: 331: 330: 329: 328: 327: 326: 325: 324: 323: 322: 321: 320: 319: 318: 317: 316: 315: 314: 313: 312: 311: 310: 309: 308: 307: 306: 305: 304: 303: 302: 301: 300: 299: 298: 297: 296: 295: 294: 293: 292: 291: 290: 289: 288: 287: 286: 285: 284: 283: 282: 281: 280: 279: 278: 277: 276: 275: 274: 273: 272: 271: 270: 269: 268: 267: 266: 265: 264: 263: 262: 261: 260: 259: 258: 257: 256: 255: 254: 253: 252: 251: 250: 249: 248: 247: 246: 245: 244: 243: 242: 241: 240: 239: 238: 237: 236: 235: 234: 233: 232: 231: 230: 229: 228: 227: 226: 225: 224: 223: 222: 221: 220: 219: 218: 217: 216: 215: 214: 213: 212: 211: 210: 209: 208: 207: 206: 205: 204: 203: 202: 201: 200: 199: 198: 197: 196: 195: 194: 193: 192: 191: 190: 189: 188: 187: 186: 185: 184: 183: 182: 181: 180: 179: 178: 177: 176: 175: 174: 173: 172: 171: 170: 169: 168: 167: 166: 165: 164: 163: 162: 161: 160: 159: 158: 157: 156: 155: 154: 153: 152: 151: 150: 149: 148: 147: 146: 145: 144: 143: 142: 141: 140: 139: 138: 137: 136: 135: 134: 133: 132: 131: 130: 129: 128: 127: 126: 125: 124: 123: 122: 121: 120: 119: 118: 117: 116: 115: 114: 113: 112: 111: 110: 109: 108: 107: 106: 105: 104: 103: 102: 101: 100: 99: 98: 97: 96: 95: 94: 93: 92: 91: 90: 89: 88: 87: 86: 85: 84: 83: 82: 81: 80: 79: 78: 77: 76: 75: 74: 73: 72: 71: 70: 69: 68: 67: 66: 65: 64: 63: 62: 61: 60: 59: 58: 57: 56: 55: 54: 53: 52: 51: 50: 49: 48: 47: 46: 45: 44: 43: 42: 41: 40: 39: 38: 37: 36: 35: 34: 33: 32: 31: 30: 29: 28: 27: 26: 25: 24: 23: 22: 21: 20: 19: 18: 17: 16: 15: 14: 13: 12: 11: 10: 9: 8: 7: 6: 5: 4: 3: 2: 1: 0

↓ where to cap the possible design

517 AC 516: 500: 515: 514: 513: 512: 511: 510: 509: 508: 507: 506: 505: 504: 503: 502: 501: 500: 499: 498: 497: 496: 495: 494: 493: 492: 491: 490: 489: 488: 487: 486: 485: 484: 483: 482: 481: 480: 479: 478: 477: 476: 475: 474: 473: 472: 471: 470: 469: 468: 467: 466: 465: 464: 463: 462: 461: 460: 459: 458: 457: 456: 455: 454: 453: 452: 451: 450: 449: 448: 447: 446: 445: 444: 443: 442: 441: 440: 439: 438: 437: 436: 435: 434: 433: 432: 431: 430: 429: 428: 427: 426: 425: 424: 423: 422: 421: 420: 419: 418: 417: 416: 415: 414: 413: 412: 411: 410: 409: 408: 407: 406: 405: 404: 403: 402: 401: 400: 399: 398: 397: 396: 395: 394: 393: 392: 391: 390: 389: 388: 387: 386: 385: 384: 383: 382: 381: 380: 379: 378: 377: 376: 375: 374: 373: 372: 371: 370: 369: 368: 367: 366: 365: 364: 363: 362: 361: 360: 359: 358: 357: 356: 355: 354: 353: 352: 351: 350: 349: 348: 347: 346: 345: 344: 343: 342: 341: 340: 339: 338: 337: 336: 335: 334: 333: 332: 331: 330: 329: 328: 327: 326: 325: 324: 323: 322: 321: 320: 319: 318: 317: 316: 315: 314: 313: 312: 311: 310: 309: 308: 307: 306: 305: 304: 303: 302: 301: 300: 299: 298: 297: 296: 295: 294: 293: 292: 291: 290: 289: 288: 287: 286: 285: 284: 283: 282: 281: 280: 279: 278: 277: 276: 275: 274: 273: 272: 271: 270: 269: 268: 267: 266: 265: 264: 263: 262: 261: 260: 259: 258: 257: 256: 255: 254: 253: 252: 251: 250: 249: 248: 247: 246: 245: 244: 243: 242: 241: 240: 239: 238: 237: 236: 235: 234: 233: 232: 231: 230: 229: 228: 227: 226: 225: 224: 223: 222: 221: 220: 219: 218: 217: 216: 215: 214: 213: 212: 211: 210: 209: 208: 207: 206: 205: 204: 203: 202: 201: 200: 199: 198: 197: 196: 195: 194: 193: 192: 191: 190: 189: 188: 187: 186: 185: 184: 183: 182: 181: 180: 179: 178: 177: 176: 175: 174: 173: 172: 171: 170: 169: 168: 167: 166: 165: 164: 163: 162: 161: 160: 159: 158: 157: 156: 155: 154: 153: 152: 151: 150: 149: 148: 147: 146: 145: 144: 143: 142: 141: 140: 139: 138: 137: 136: 135: 134: 133: 132: 131: 130: 129: 128: 127: 126: 125: 124: 123: 122: 121: 120: 119: 118: 117: 116: 115: 114: 113: 112: 111: 110: 109: 108: 107: 106: 105: 104: 103: 102: 101: 100: 99: 98: 97: 96: 95: 94: 93: 92: 91: 90: 89: 88: 87: 86: 85: 84: 83: 82: 81: 80: 79: 78: 77: 76: 75: 74: 73: 72: 71: 70: 69: 68: 67: 66: 65: 64: 63: 62: 61: 60: 59: 58: 57: 56: 55: 54: 53: 52: 51: 50: 49: 48: 47: 46: 45: 44: 43: 42: 41: 40: 39: 38: 37: 36: 35: 34: 33: 32: 31: 30: 29: 28: 27: 26: 25: 24: 23: 22: 21: 20: 19: 18: 17: 16: 15: 14: 13: 12: 11: 10: 9: 8: 7: 6: 5: 4: 3: 2: 1: 0

↓ record the decisionative anchors